# Introduction générale au XML et à la TEI

## Atelier Humanités Numériques & Lyon

Matthias Gille Levenson

Université Versailles Saint Quentin (UVSQ) & École Normale Supérieure de Lyon, France

matthias [dot] gille [-] levenson [at] ens-lyon [dot] fr

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI?

4 La TEI, pour quoi faire?

5 Projets utilisant la TEI

# Accès aux slides

- https://github.com/matgille/Antidote_workshop_2025_ODD.git

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI?

4 La TEI, pour quoi faire?

5 Projets utilisant la TEI

# eXtensible Marking Language

- XML stands for **eXtensible Markup Language**.
- It is a format that allows to describe any kind of textual (or numeric) data
- It is the actual *format* the TEI uses, but it might change/evolve in the future.

# Two important concepts: Conformité and validity

- Un document **doit** être conforme au XML, c'est-à-dire respecter l'ensemble des règles du XML
- Un document **peut** être validé par un **schéma**, c'est-à-dire un document qui vérifie des règles propres à une spécification particulière
- Quelques spécifications XML: TEI, EAD, DublinCore, AltoXML, PageXML, RDF, etc...
- Nous nous intéresserons à la validité des documents XML dans la seconde session de la formation.

# Conformité

- XML is composed of elements, attributes, attribute values and text.

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xml:id="drp" xmlns="http://www.tei-c.org/ns/1.0">
   <teiHeader>
      <fileDesc>
         <titleStmt>
            <author cert="low">Matthias Gille Levenson</author>
         </titleStmt>
         <publicationStmt>
            <publisher>Unpublished</publisher>
            <availability>
               <licence>Creative Commons CC BY-NC-SA 4.0 FR</licence>
            </availability>
         </publicationStmt>
      </fileDesc>
   </teiHeader>
</TEI>
```

Figure: Ce document XML est conforme (but incorrect/incomplete TEI)

# Recap: vocabulary

Four main objects (called *nodes*):

- **Element** nodes: the basic object of any XML document: `<elementName/>` or `<elementName>...</elementName>`
- **Attribute** nodes: part of an element that helps specifying it: `attributeName="value"`
- **Text nodes**: every textual object inside an element
- **Comment** nodes: content not parsed by the machine: `<!-- some useful comment -->`

# The root node/element

- One and only one top element that contains everything else

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xml:id="drp" xmlns="http://www.tei-c.org/ns/1.0">
   <teiHeader>
      <fileDesc>
         <titleStmt>
            <author cert="low">Matthias Gille Levenson</author>
         </titleStmt>
         <publicationStmt>
            <publisher>Unpublished</publisher>
            <availability>
               <licence>Creative Commons CC BY-NC-SA 4.0 FR</licence>
            </availability>
         </publicationStmt>
      </fileDesc>
   </teiHeader>
</TEI>
```

Figure: Ce document XML est **conforme** (mais la TEI est **invalide**)

# Conformité

- *No* overlapping elements

```
<?xml version="1.0" encoding="UTF-8"?>
<TEXT xml:id="drp" xmlns="http://www.tei-c.org/ns/1.0">
  <NODE_A>Hello <NODE_B>World</NODE_A></NODE_B>
</TEXT>
```

Figure: Ce document XML est non conforme

# Conformité

- Some elements can contain other elements, but elements can also be empty

```
<?xml version="1.0" encoding="UTF-8"?>
<div type="chapitre" n="1">
   <lb/>ca . i. quomodo diuiduntur potentiae
   <lb/>anime et inquibus potenciis
   <lb/>habent esse
   <lb/>uirtutes
</div>
```

Figure: Ce document XML est conforme

# Conformité

- Les valeurs d'attributs vont entre guillemets

```
<?xml version="1.0" encoding="UTF-8"?>
<TEXT>
   <NODE_A type=sentence>Hello
      <NODE_B>World</NODE_B>
   </NODE_A>
</TEXT>
```

Figure: Ce document XML est non conforme

# Conforme? Non conforme?

```
<sentence>Longtemps, je me suis couché de bonne heure.</sentence>

<sentence>Longtemps, je me suis couché de bonne heure.<sentence>

<sentence type=incipit>Longtemps, je me suis couché<linebreak></linebreak> de bonne heure.</sentence>

<sentence type=incipit>Longtemps, je me suis couché<linebreak/> de bonne heure.</sentence>

<sentence>Longtemps, je me suis couché de bonne heure.</sent>

<sentence type="incipit">Longtemps, je me suis couché de bonne heure.</sentence>

<paragraph>
        <sentence type="incipit">Longtemps, je me suis couché <strikethrough>de bonne heure.</sentence>
        <sentence>Parfois, à peine ma bougie éteinte</strikethrough>,
            mes yeux se fermaient si vite que je n’avais pas le temps de me dire</sentence>
</paragraph>

<paragraph>
        <sentence type="incipit">Longtemps, je me suis couché <strikethrough>de bonne heure.</strikethrough></sentence>
        <sentence><strikethrough>Parfois, à peine ma bougie éteinte</strikethrough>,
            mes yeux se fermaient si vite que je n’avais pas le temps de me dire</sentence>
</paragraph>
```

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI?

4 La TEI, pour quoi faire?

5 Projets utilisant la TEI

3 Qu'est-ce que la TEI?
- Ce qu'est la TEI
- Ce que n'est pas la TEI
- Principes

# Qu'est-ce que la TEI?

- Une communauté scientifique
- Une "standard" et un ensemble de règles, les *Guidelines*: `https://tei-c.org/release/doc/tei-p5-doc/en/html/`
- Une façon de se représenter / modéliser "le" texte

3 Qu'est-ce que la TEI?
- Ce qu'est la TEI
- Ce que n'est pas la TEI
- Principes

# Ce que n'est pas la TEI

- Un outil de visualisation des sources textuelles
- Un outil de transformation des sources textuelles

3 Qu'est-ce que la TEI?
- Ce qu'est la TEI
- Ce que n'est pas la TEI
- Principes

- Separate the appearance and the "essence" of textual objects

del mal del otro o del buen zelo[3]. Si del mal, cuidando que non devía el omne sofrir tal mal, esta es misericordia, ca misericordia non es otra cosa sinon tristeza del mal que omne sufre sin meresçimiento, segund que dize el philósofo en el IIº de la *Retórica*; mas si toma tristeza del bien, esto es en dos maneras, ca o le pesa del bien que otri ha, maguer que lo él meresca de aver, e esta es enbidia, ca enbidia non es otra cosa sinon // [Fol. 176r] dolor o tristeza del bien que otro ha[4]; [mas si le pesa del bien que otro ha] porque lo non meresçe aver, (e) así es némesis o

[3] del buen zelo ] del bien *Glosa*.

[4] En este punto ha producido un salto de texto de igual a igual respecto a la *Glosa*, donde se lee seguidamente el texto que transcribo entre corchetes, que es necesario para que el sentido del pasaje no quede truncado.

[5] [a los mayores] ] *om. Castigos* respecto a la *Glosa*.

Figure: Fragment of an edition of the *Castigos de Sancho IV* (Marín Sánchez 2003)

- Séparer l'apparence et l'"essence" des objets textuels

```
<p>del mal del otro o
  <app>
    <lem>del buen zelo</lem>
    <rdg wit="#Glosa">del bien</rdg>
  </app>
   . Si del mal, cuidando que non devía el omne sofrir tal mal, esta es misericordia, ca
  misericordia non es otra cosa sinon tristeza del mal que omne sufre sin meresçimiento,
  segund que dize el philósofo en el IIo de la Retórica; mas si toma tristeza del bien,
  esto es en dos maneras, ca o le pesa del bien que otri ha, maguer que lo él meresca de
  aver, e esta es enbidia, ca enbidia non es otra cosa sinon<pb n="176r"/> dolor o
  tristeza del bien que otro ha;
  <choice>
    <sic>mas si le pesa del bien que otro ha</sic>
    <corr/>
  </choice>
  <note>En este punto ha producido un salto de texto de igual a igual respecto a la Glosa,
    donde se lee seguidamente el texto que transcribo, que es necesario
    para que el sentido del pasaje no quede truncado.</note> porque lo non meresçe aver,
    <supplied>e</supplied> así es némesis o desdén</p>
```

Figure: Its possible representation in XML-TEI

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI?

4 La TEI, pour quoi faire?

5 Projets utilisant la TEI

# La TEI, pour quoi faire?

- Describing a text using the experience of a **large community**
- Producing semantic data that can be **read** by the human and **processed** by the computer
- Make sharing and reusability of these representations easier

4 La TEI, pour quoi faire?
- Décrire des textes / traiter des représentations textuelles

# Un exemple de traitement du texte: la collation automatisée

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI?

4 La TEI, pour quoi faire?

5 Projets utilisant la TEI

# References

Marín Sánchez, Ana María. “La Versión Interpolada de Los Castigos de Sancho IV: Edición y Estudio”. PhD thesis. Universidad de Zaragoza, 2003.