Session 1 : Introduction générale au XML

Atelier Humanités Numériques

Lyon

Matthias Gille Levenson

Université Versailles Saint Quentin (UVSQ) & École Normale Supérieure de Lyon, France

matthias [dot] gille [-] levenson [at] ens-lyon [dot] fr

24 mars 2026

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI ?

4 La TEI, pour quoi faire ?

5 Exemples utilisés au long de la formation

Accès aux diapos

- https ://github.com/matgille/formation_TEI_AHN_mars_2026.git

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI ?

4 La TEI, pour quoi faire ?

5 Exemples utilisés au long de la formation

2 Le format XML
- Qu'est-ce que le XML ?
- Conformité et validité

eXtensible Marking Language

- XML signifie **eXtensible Markup Language**.
- Il s'agit d'un format qui permet de décrire tout type de données textuelles (ou numériques)
- Il s'agit du *format* actuellement utilisé par le TEI, mais il est susceptible de changer ou d'évoluer à l'avenir.

Composants principaux du XML

- Le XML peut être décomposés en éléments principaux, qu'on appelle des **noeuds**
- Les noeuds principaux sont : le texte, les éléments, les attributs, les commentaires.
- Ces noeuds sont représentés à l'aide de caractères spécifiques

Vocabulaire

Quatre objets principaux (appelés *nœuds*) :

- Nœuds **éléments** : l'objet de base de tout document XML : `<elementName/>` ou `<elementName>...</elementName>`
- Nœuds **attributs** : partie d'un élément qui permet de le définir : `attributeName="value"`
- Nœuds **texte** : tout objet textuel contenu dans un élément
- Nœuds **Commentaire** : contenu non traité par la machine : `<!-- un commentaire utile -->`

2 Le format XML
- Qu'est-ce que le XML ?
- Conformité et validité
  - Corriger un XML mal structuré

Conformité et validité

- Un document **doit** être conforme au XML, c'est-à-dire respecter l'ensemble des règles du XML
- Un document **peut** être validé par un **schéma**, c'est-à-dire un document qui vérifie des règles propres à une spécification particulière
- Quelques spécifications XML : TEI, EAD, DublinCore, AltoXML, PageXML, RDF, etc...
- Nous nous intéresserons à la validité des documents XML dans la seconde session de la formation.

Conformité. Composants principaux du XML

- Il existe peu de règles en XML mais elles sont fondamentales :
  1. Du point de vue de la *modélisation* (représentation abstraite de l'objet XML)
     - Règle d'enchâssement des éléments
     - Règle d'unicité des attributs
  2. Du point de vue de la *sérialisation* (expression de l'objet XML à l'aide d'une chaîne de caractères)
     - Règles d'expression d'un élément : `<element/>`, `<element>contenu</element>`
     - Règle d'expression des attributs : espaces et guillemets obligatoires
- **En XML** ($\neq$ TEI), il n'y a pas de règle quant au nom des éléments (d'où « eXtensible »)

Conformité

- Un seul et unique élément de niveau supérieur qui contient tout le reste

```
<?xml version="1.0" encoding="UTF-8"?>
<TEI xml:id="drp" xmlns="http://www.tei-c.org/ns/1.0">
   <teiHeader>
      <fileDesc>
         <titleStmt>
            <author cert="low">Matthias Gille Levenson</author>
         </titleStmt>
         <publicationStmt>
            <publisher>Unpublished</publisher>
            <availability>
               <licence>Creative Commons CC BY-NC-SA 4.0 FR</licence>
            </availability>
         </publicationStmt>
      </fileDesc>
   </teiHeader>
</TEI>
```

Figure – Ce document XML est **conforme** (mais la TEI est **invalide**)

Conformité

- *Pas* d'éléments qui se chevauchent

```
<?xml version="1.0" encoding="UTF-8"?>
<TEXT xml:id="drp" xmlns="http://www.tei-c.org/ns/1.0">
  <NODE_A>Hello <NODE_B>World</NODE_A></NODE_B>
</TEXT>
```

Figure – Ce document XML est non conforme

Conformité

- Certains éléments peuvent contenir d'autres éléments, mais ils peuvent aussi être vides

```
<?xml version="1.0" encoding="UTF-8"?>
<div type="chapitre" n="1">
   <lb/>ca . i. quomodo diuiduntur potentiae
   <lb/>anime et inquibus potenciis
   <lb/>habent esse
   <lb/>uirtutes
</div>
```

Figure – Ce document XML est conforme

Conformité

- Les valeurs d'attributs sont entre guillemets

```
<?xml version="1.0" encoding="UTF-8"?>
<TEXT>
   <NODE_A type=sentence>Hello
      <NODE_B>World</NODE_B>
   </NODE_A>
</TEXT>
```

Figure – Ce document XML est non conforme

Conforme ? Non conforme ?

```
<sentence>Longtemps, je me suis couché de bonne heure.</sentence>

<sentence>Longtemps, je me suis couché de bonne heure.<sentence>

<sentence type=incipit>Longtemps, je me suis couché<linebreak></linebreak> de bonne heure.</sentence>

<sentence type=incipit>Longtemps, je me suis couché<linebreak/> de bonne heure.</sentence>

<sentence>Longtemps, je me suis couché de bonne heure.</sent>

<sentence type="incipit">Longtemps, je me suis couché de bonne heure.</sentence>

<paragraph>
        <sentence type="incipit">Longtemps, je me suis couché <strikethrough>de bonne heure.</sentence>
        <sentence>Parfois, à peine ma bougie éteinte</strikethrough>,
            mes yeux se fermaient si vite que je n'avais pas le temps de me dire</sentence>
</paragraph>

<paragraph>
        <sentence type="incipit">Longtemps, je me suis couché <strikethrough>de bonne heure.</strikethrough></sentence>
        <sentence><strikethrough>Parfois, à peine ma bougie éteinte</strikethrough>,
            mes yeux se fermaient si vite que je n'avais pas le temps de me dire</sentence>
</paragraph>

```

2 Le format XML
- Qu'est-ce que le XML ?
- Conformité et validité
  - Corriger un XML mal structuré

Oxygen

- Oxygen XML editor est l'outil le plus utilisé, car il est développé en collaboration avec des utilisateur.ices de la TEI.
- Il s'agit d'un outil propriétaire qui peut être remplacé par d'autres logiciels comme Jedit

Raccourcis clavier dans Oxygen

La touche `ACTION` correspond à CTRL sur Windows/Linux et POMME sur Mac.

- Créer un nouveau document : `ACTION + N`
- Ouvrir un nouveau document : `ACTION + O`
- Indenter (mettre en forme pour rendre lisible avec des sauts de lignes et des tabulations) : `ACTION + SHIFT + P`
- Commenter un fragment de document XML : `ACTION + SHIFT + ,`
- Créer un élément parent autour d'un ensemble de noeuds textuels ou éléments : `ACTION + E`

Application

La touche ACTION correspond à CTRL sur Windows/Linux et POMME sur Mac.

- Ouvrez le document `session_1_introduction_generale/exercices/exercice_1.xml`
- Indentez le document. Que se passe-t-il ?
- Tâchez de réparer la structure afin d'avoir du XML conforme.
- La lecture des messages d'erreur est souvent bien utile !

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI ?

4 La TEI, pour quoi faire ?

5 Exemples utilisés au long de la formation

3 Qu'est-ce que la TEI?
- Ce qu'est la TEI
- Ce que n'est pas la TEI
- Principes

Qu'est-ce que la TEI ?

- Une communauté scientifique
- Une « standard » et un ensemble de règles, les *Guidelines* : `https://tei-c.org/release/doc/tei-p5-doc/en/html/`
- Une façon de se représenter / modéliser « le » texte

3 Qu'est-ce que la TEI?
- Ce qu'est la TEI
- Ce que n'est pas la TEI
- Principes

Ce que n'est pas la TEI

- Un outil de visualisation des sources textuelles
- Un outil de transformation des sources textuelles

Ce qu'il vous faudra apprendre

- Un langage de navigation dans le XML (XPath)
- Un langage de transformation du XML pour la visualisation (XSLT, HTML)

3 Qu'est-ce que la TEI ?
- Ce qu'est la TEI
- Ce que n'est pas la TEI
- Principes

- Distinguer l'apparence et l'« essence » des objets textuels
- Décrire cette « essence » selon un **consensus scientifique**

del mal del otro o del buen zelo[3]. Si del mal, cuidando que non devía el omne sofrir tal mal, esta es misericordia, ca misericordia non es otra cosa sinon tristeza del mal que omne sufre sin meresçimiento, segund que dize el philósofo en el IIº de la *Retórica*; mas si toma tristeza del bien, esto es en dos maneras, ca o le pesa del bien que otri ha, maguer que lo él meresca de aver, e esta es enbidia, ca enbidia non es otra cosa sinon // [Fol. 176r] dolor o tristeza del bien que otro ha[4]; [mas si le pesa del bien que otro ha] porque lo non meresçe aver, (e) así es némesis o

[3] del buen zelo] del bien *Glosa*.

[4] En este punto ha producido un salto de texto de igual a igual respecto a la *Glosa*, donde se lee seguidamente el texto que transcribo entre corchetes, que es necesario para que el sentido del pasaje no quede truncado.

[5] [a los mayores]] *om. Castigos* respecto a la *Glosa*.

Figure – Fragment d'une édition des *Castigos de Sancho IV* (Marín Sánchez 2003)

```
<p>del mal del otro o
  <app>
    <lem>del buen zelo</lem>
    <rdg wit="#Glosa">del bien</rdg>
  </app>
   . Si del mal, cuidando que non devía el omne sofrir tal mal, esta es misericordia, ca
  misericordia non es otra cosa sinon tristeza del mal que omne sufre sin meresçimiento,
  segund que dize el philósofo en el IIo de la Retórica; mas si toma tristeza del bien,
  esto es en dos maneras, ca o le pesa del bien que otri ha, maguer que lo él meresca de
  aver, e esta es enbidia, ca enbidia non es otra cosa sinon<pb n="176r"/> dolor o
  tristeza del bien que otro ha;
  <choice>
    <sic>mas si le pesa del bien que otro ha</sic>
    <corr/>
  </choice>
  <note>En este punto ha producido un salto de texto de igual a igual respecto a la Glosa,
    donde se lee seguidamente el texto que transcribo, que es necesario
    para que el sentido del pasaje no quede truncado.</note> porque lo non meresçe aver,
    <supplied>e</supplied> así es némesis o desdén</p>
```

Figure – Une représentation possible en XML-TEI

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI ?

4 La TEI, pour quoi faire ?

5 Exemples utilisés au long de la formation

La TEI, pour quoi faire ?

La TEI est le standard de fait pour le partage des données actuellement

- Pour décrire un objet textuel en utilisant l'expérience d'une communauté
- Pour produire des données qui peuvent être **lues** par l'être humain et **traitées** par la machine
- Pour faciliter l'échange de ces descriptions
- Pour faciliter l'interopérabilité des données

La critique génétique

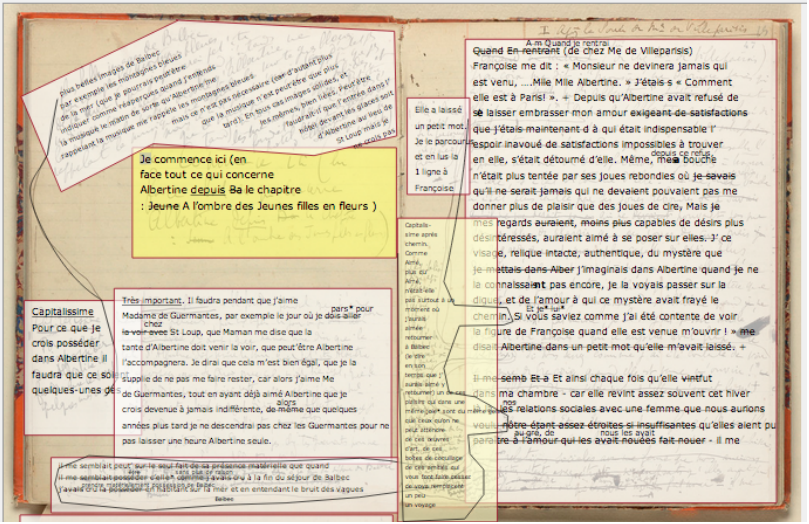

Figure – L'édition des brouillons de Proust (André et Pierazzo 2013)

L'édition critique

Chapitre 10 Traduction Version A bis

la az de los caualleros como delos peones son de estableçer cabdiellos e mayorales e alferezes que lieuen los pendones por que cada vno sepa lo que ha de fazer· por que tan grande es el espanto en la batalla ponr el roydo delas armas e por los colpes que se dan que las palabras e las guaniçiones non abastan para guiar los lidiadores/· Mas conuiene de dar otras senna les manifiestas· por que cada vno viendo aquellas senuales se sepa tener ordenadamente en su az e sepa que ha de fazer/ e desto pueda pareçer quales deuen ser los que lieuan los pendones e las senuales· ca la sennal rompida/ o tomada toda la hueste es confondida e desordenada/·

3 Et pues que assi es con grant sabiduria es de[bd. 186a] escoger el alferez assi que sea fuerte de cuerpo e firme de coraçon e fiel a su principe e a su sennor e prouado en las armas e que ayan todas las otras cosas que son menester a bueno e a estremado lidiador por que avn contesçio enel nfo tiempo que todo el pueblo dela çibdat fue vençido de pocos lidiadores/· por que el alferez que leuaua la senna fizo fabedat encubriendo la senna e escondiendo la /· Por la qual cosa fueron confondidos los lidiadores assi que non auian cabeça nin sabian a quien auian de tener mientes /· Et por ende sien la batalla la uida e el estado de muchos omes es puesta a periglos de muerte con grant acuçia e con grant diligençia deue ser escogido el alferez/· de las cosas sobredichas puede pareçer qual deua ser el cabdiello que deue ser ante puesto en la hueste tan bien a los peones como a los caualleros/· ca assi comno la cabeça es meior e mas noble que todos los otros mienbros/· Assi el que deue ser ante puesto en la batalla· a alguans conpannas / o algunos lidiadores deue ser meior e mas estremado lidiador que ellos e mas prouado en aquellas cosas que son menester para la batalla por la qual cosa como los peones si quisieren ser buenos lidiadores deuan ser fuertes e rezios en los sus cuerpos e altos en el estado del cuerpo e que sepan lançar lanças e dardos/· e avn que sepan esgrimir las espadas para ferir meior e rodear el escudo para encobrirse meior e avn que ayan los oios bien espiertos e que sean ligeros e mesurados en beuer e gerrdados de vino e avn que ayan vso delas armas/· Et si

196

Version B Traduction Chapitre 10

3 Lo iii^a^, conviene de señalar cavalleros estremados que lieven las señas en las faziendas. Et éstos deven ser escogidos entre todos los otros, asý que sean fuertesde cuerpo, e rrezios de coraçón, e fieles al rrey o al principe, e provados en las armas, e que ayan todas aquellas condiciones que pertenesçen a buenbue[6a] lidiador. Ca quebrantada la saña, toda la hueste es confondida : onde 30R
cuenta este doctor que en el su tienpo fue vençido todo el pueblo de una çibdat de muy pocos cavalleros, porque el alferez fue muy malo, e ascondió la seña : et asý non sabían a quién[b] avían de[c] tener mientes, e fueron todos vençidos. Et por ende deve ser muy escogido el alferez o el que lieva la seña o el pendón.

28 fuertes *AGRBJZQ* | fuertes e rrezios *Q*

27 señas QMGRBJZ | señales *J* 28 cuerpo *AGRBJZ* | cocrpos *QJ* 28 rrezios *RBJAGZ* | om. *Q* 29 o QGRBJZ | e *A* 29 e QABJZ | om. *G* et *R* 29 ayan QMGBJZ | ayas[bd] *R* 29 todas *AGRBJZ* | om. *Q* 30 saña B | seña *QAGRZ* señal *J* 31 el *AGBJZ* | om. *QR* 32 porque QGRBJZ | por *A* 32 porque *QGRBJZ* | porque que *A* 32 asý *RBAGZZ* | om. *Q* 32 sabían *QB* | sabiendo *AGRJZ* 33 e *QB* | om. *AGRJZ* 33 todos *QRB* | om. *AGJZ* 33 vençidos *QRB* | vençidos todos *AGJZ* 33 lieva *QRBJAZ* | lleva *G* 34 o QARBJZ | et *G*

197

Figure – Un exemple d'édition critique numérique (Gille Levenson 2023)

La collation automatisée

```
for rdg in apps:
    if rdg.is_empty() and following_rdg.is_empty():
            create_node(witEnd)
```

Figure – Pseudo-code décrivant l'insertion automatisée de balises de lacunes textuelles

L'alignement multilingue de sources vernaculaires médiévales

```
−<p>
 −<cl xml:id="g96FRSs" corresp="#yn4oUP5 #xrhHCae">
    <w lemma="tertius" pos="ADJord" morph="NOMB.=Sing">Tertio</w>
    <w lemma="politicus" pos="NOMcom" morph="CAS=Gen|NOMB.=Plur">Politicorum</w>
    <w lemma="distinguo" pos="VER" morph="MODE=Ind|NOMB.=Sing|PERS.=3|TEMPS=Pres">distinguit</w>
    <w lemma="philosophus" pos="NOMcom" morph="CAS=Nom|NOMB.=Sing">Philosophus</w>
    <w lemma="sex" pos="ADJcar" morph="CAS=Ind">sex</w>
    <w lemma="modus" pos="NOMcom" morph="CAS=Acc|NOMB.=Plur">modos</w>
    <w lemma="principo" pos="VER" morph="CAS=Gen|MODE=Par|NOMB.=Plur|TEMPS=Pres">principantium</w>
    <pc lemma="e" pos="INJ">,</pc>
  </cl>
 −<cl xml:id="kzBdLU9" corresp="#pbkL19E">
    <w lemma="qui" pos="PROrel" morph="CAS=Gen|NOMB.=Plur">quorum</w>
    <w lemma="tres" pos="ADJcar" morph="CAS=Nom|NOMB.=Plur">tres</w>
    <w lemma="sum" pos="VER" morph="MODE=Ind|NOMB.=Plur|PERS.=3|TEMPS=Pres">sunt</w>
    <w lemma="bonus" pos="NOMcom" morph="CAS=Nom|NOMB.=Plur">boni</w>
    <pc lemma="e" pos="INJ">,</pc>
  </cl>
 −<cl xml:id="jpynT4X" corresp="#sCRYI2Q">
    <w lemma="et" pos="CONcoo">et</w>
    <w lemma="tres" pos="ADJcar" morph="CAS=Nom|NOMB.=Plur">tres</w>
    <w lemma="sum" pos="VER" morph="MODE=Ind|NOMB.=Plur|PERS.=3|TEMPS=Pres">sunt</w>
    <w lemma="malum" pos="NOMcom" morph="CAS=Gen|NOMB.=Sing">mali</w>
    <pc lemma="anter" pos="NOMcom" morph="CAS=Voc|MODE=Par|NOMB.=Plur|TEMPS=Perf">.</pc>
  </cl>
```

```
−<p>
 −<cl xml:id="yn4oUP5" corresp="#g96FRSs">
    <w lemma="el" pos="DA0MS0">el</w>
    <w lemma="3" pos="AO0MS0">terçero</w>
    <w lemma="libro" pos="NCMS000">libro</w>
    <w lemma="delas_de+delas_el" pos="SP+DA">delas</w>
    <w lemma="política" pos="NCFP000">politicas</w>
  </cl>
 −<cl xml:id="xrhHCae" corresp="#g96FRSs">
    <w lemma="departir" pos="VMIP3S0">departe</w>
    <w lemma="el" pos="DA0MS0">el</w>
    <w lemma="filósofo" pos="NCMS000">philosofo</w>
    <w lemma="seis" pos="AQ0MS0">seys</w>
    <w lemma="linaje" pos="NCMP000">linaies</w>
    <w lemma="de" pos="SPS00">de</w>
    <w lemma="principado" pos="NCMP000">prinçipados</w>
  </cl>
 −<cl xml:id="pbkL19E" corresp="#kzBdLU9">
    <w lemma="de" pos="SPS00">de</w>
    <w lemma="el" pos="DA0MP0">los</w>
    <w lemma="cuál" pos="PT0CP000">quales</w>
    <w lemma="tro" pos="SPS00">tro</w>
    <w lemma="ser" pos="VSIP3P0">son</w>
    <w lemma="bueno" pos="AQ0MP0">buenos</w>
  </cl>
 −<cl xml:id="sCRYI2Q" corresp="#jpynT4X">
    <w lemma="e" pos="CC">e</w>
    <w lemma="el" pos="DA0MP0">los</w>
    <w lemma="trsson" pos="NCMS000">trsson</w>
    <w lemma="malo" pos="AQ0MP0">malos</w>
    <pc lemma="." pos="Fp">.</pc>
  </cl>
```

1 Introduction

2 Le format XML

3 Qu'est-ce que la TEI ?

4 La TEI, pour quoi faire ?

5 Exemples utilisés au long de la formation

- L'incipit de la *Recherche du temps perdu* de Proust
- Un sonnet de Rimbaud
- Une scène de *L'avare* de Molière

References

André, Julie et Elena Pierazzo. « Le codage en TEI des brouillons de Proust : vers lédition numérique ». In : *Genesis* 36 (2013), p. 155–161. ISSN : 1167-5101, 2268-1590. DOI : 10.4000/genesis.1159.

Gille Levenson, Matthias. « Le Regimiento de Los Prínçipes et Sa Glose : Étude et Édition Numérique de La Partie Sur Le Gouvernement de La Cité En Temps de Guerre (III, 3). ». Lyon : École Normale Supérieure de Lyon, 2023.

Marín Sánchez, Ana María. « La Versión Interpolada de Los Castigos de Sancho IV : Edición y Estudio ». Thèse de doct. Universidad de Zaragoza, 2003.