Session 2 : la TEI

Atelier Humanités Numériques

Lyon

Matthias Gille Levenson

Université Versailles Saint Quentin (UVSQ) & École Normale Supérieure de Lyon, France

matthias [dot] gille [-] levenson [at] ens-lyon [dot] fr

24 mars 2026

1 Organisation de la TEI

2 Application : encoder des vers et du théâtre

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux

Éléments proposés par la TEI

- La TEI propose d'utiliser un certain nombre d'éléments définis en amont.
- Faire de la TEI, c'est utiliser ce jeu d'éléments pour décrire un objet textuel.
- Exemples : l'élément `div` est utilisé pour indiquer une section, soit une division structurelle du texte. L'élément `p` est utilisé pour identifier des paragraphes dans des textes en prose.

Représenter l'incipit de la *Recherche*

La *Recherche* est structurée en tomes, eux-même divisés en parties et en chapitres.

```
<div>
    <div>
        <p>Longtemps, je me suis couché de bonne heure
        [...]
        </p>
    </div>
</div>
```

Attributs proposés par la TEI

- Chaque élément peut être précisé par un attribut.
- Ces attributs (sauf ceux qui commencent par `‘xml:‘`) sont également spécifiques à la TEI
- Exemple : `n` est un attribut permettant de compter un élément (un vers, par exemple, ou un chapitre)

L'utilisation d'attributs propres à la TEI

```
<div n="1">
    <div n="1">
        <p>Longtemps, je me suis couché de bonne heure
        [...]
        </p>
    </div>
</div>
```

Attributs proposés par la TEI

- Nous avons souvent besoin de préciser et de classer les différents éléments
- La TEI propose un attribut `type` pour ce faire

L'utilisation d'attributs propres à la TEI

```
<div n="1" type="partie">
    <div n="1" type="chapitre">
        <p>Longtemps, je me suis couché de bonne heure
        [...]
        </p>
    </div>
</div>
```

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux

- La TEI ne se limite pas à proposer une liste d'éléments et d'attributs
- Il est nécessaire de les définir afin de favoriser leur utilisation
- Chaque élément et chaque attribut est ainsi défini dans les Guidelines
- Taper « `TEI element` » sur votre moteur de recherche favori vous mène directement à la définition de l'élément `element` cherché.

Exemple : p

- L'élément p est défini ici :
  https ://www.tei-c.org/release/doc/tei-p5-doc/fr/html/ref-p.html

<p> (paragraphe) marque les paragraphes dans un texte en prose. (6.1 Paragraphs) (7.2.6 Speech Contents)	
Module	core — Elements available in All TEI Documents
Attributs	att.global : @xml:id, @n, @xml:lang, @xml:base, @xml:space att.global.analytic : @ana att.global.change : @change att.global.linking : @corresp, @synch, @sameAs, @copyOf, @next, @prev, @exclude, @select att.global.rendition : @rend, @style, @rendition att.global.responsible : @cert, @resp att.global.source : @source att.ascii : @form+mixed%ty att.dir.rtelem : @dir att.transcriptional : @type att.written : @lang
Membre de	model.pLike
Contenu dans	**cesr:** cesr2 **core:** note note m quote seg w abbr lb date name **corpus:** bibliography certainty certainty2nes. **drama:** castList endpoint exchanges exit speaker **figures:** cell fence **header:** abstract availability availability1 affiliation calendar change correction correspondAction correspDesc editorial1 editorial2 editorial3 encodingDesc fileDesc formerly hyphenation interpretation langUsage licence licensing1 licensing2 licensing3 licensing4 licensing5 licensing6 licensing7 licensing8 licensing9 licensing10 licensing11 licensing12 licensing13 licensing14 licensing15 licensing16 licensing17 licensing18 licensing19 licensing20 licensing21 licensing22 licensing23 licensing24 licensing25 licensing26 licensing27 licensing28 licensing29 licensing30 licensing31 licensing32 licensing33 licensing34 licensing35 licensing36 licensing37 licensing38 licensing39 licensing40

Ce que contient une page décrivant un élément

La page contient :

1. Une définition avec un renvoi vers le **module** correspondant (voir plus bas)
2. La liste des attributs autorisés
3. La définition selon le modèle de la TEI
4. Les éléments qui peuvent contenir l'élément courant
5. Les éléments contenus dans l'élément courant
6. Un exemple et un lien vers une liste d'exemples d'utilisation de l'élément

Exemple : p

1. Il est nécessaire d'aller lire la définition d'un élément avant de l'utiliser
2. Il est quasi-certain qu'il existe déjà un élément pour votre besoin
3. Ne réinventez pas la roue !

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux

- Les *Guidelines* sont organisés en chapitres qui viennent décrire un thème spécifique
- Chaque chapitre est décrit en langage naturel et vient présenter des cas typiques d'encodage.
- Avant de commencer un projet, il faut avoir lu les chapitres correspondants afin de faire les meilleurs choix possibles.
- Chaque chapitre est lié à un **module** spécifique (je reviendrai dessus plus loin)

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux
  - Métadonnées
  - Structures textuelles
  - Représentation des sources primaires
  - Description de manuscrits
  - Entités nommées
  - Apparats critiques

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux
  - Métadonnées
  - Structures textuelles
  - Représentation des sources primaires
  - Description de manuscrits
  - Entités nommées
  - Apparats critiques

Les métadonnées et le `teiHeader`

- Un document XML-TEI est composé au minimum de deux parties : les métadonnées et l'objet décrit.
- Les métadonnées, qui décrivent le document en lui-même (auteur.e, source, régime de publication, année, etc), sont renseignées dans la première partie, le `teiHeader`
- Nous allons voir les éléments `fileDesc` et `encodingDesc`, mais il en existe d'autres

`fileDesc`

- Le `fileDesc` contient toutes les informations sur le fichier encodé : son titre, son régime de distribution (licence), la source, etc.

fileDesc > titleStmt

- Le `titleStmt` contient l'information sur le titre **du document XML**, qui peut différer du titre de la ou des sources utilisées.

```
<fileDesc>
    <titleStmt>
      <title>The shortest possible TEI document</title>
    </titleStmt>
    ...
</fileDesc>
```

fileDesc > titleStmt

- Le `titleStmt` contient également toute information sur l'origine et la création du document TEI décrit : autorité, traduction, édition, financements, responsabilité intellectuelle (en cas de multiples auteurs).
- Éléments importants : `respStmt` `resp`, `name`, `author`, `editor`, etc

```
<fileDesc>
    <titleStmt>
      <title>The shortest possible TEI document</title>
    </titleStmt>
    <respStmt>
      <resp>created by</resp>
      <name>Ann O'Nyme</name>
    </respStmt>
</fileDesc>
```

fileDesc > publicationStmt

- Le publicationStmt donne des informations sur le contexte de publication et de diffusion du document (propriété intellectuelle essentiellement)

```
<publicationStmt>
    <distributor>ATILF (Analyse et Traitement Informatique de la Langue
    ↪  Française)</distributor>
    <idno type="FRANTEXT">L434</idno>
    <address>
        <addrLine>44, avenue de la Libération</addrLine>
        ...
        <addrLine>FRANCE</addrLine>
    </address>
    <availability status="free">
        <p>Dans un cadre de recherche ou d'enseignement</p>
    </availability>
</publicationStmt>
```

fileDesc > sourceDesc

- L'élément `sourceDesc` permet de décrire la source utilisée pour l'encodage (manuscrit, audio, livre imprimé).

```
<sourceDesc>
    <bibl>
        The first folio of Shakespeare, prepared by Charlton Hinman (The
        ↪  Norton Facsimile, 1968)
    </bibl>
</sourceDesc>
```

encodingDesc

- L'`encodingDesc` contient des informations sur la façon d'encoder le document en cours. Cette description sera réalisée en language naturel, au sein d'un `editorialDecl` puis d'un paragraphe.

```
<encodingDesc>
    <editorialDecl>
        <p>
            Basic encoding, capturing lexical information only. All
            ↪ hyphenation, punctuation, and variant spellings normalized.
            ↪ No formatting or layout information preserved.
        </p>
    </editorialDecl>
</encodingDesc>
```

encodingDesc > projectDesc

- L'encodingDesc peut contenir également un élément projectDesc. Cet élément vient décrire le cadre de l'encodage du fichier.

```
<encodingDesc>
    <projectDesc>
        <p>
            Ce document contient l'ensemble des fichiers XML de ma thèse de
            ↪  doctorat, réalisé sous la direction de Carlos Heusch (Ens de
            ↪  Lyon) et de Jesús R. Velasco (Yale University), soutenue le 8
            ↪  septembre 2023.
        </p>
    </projectDesc>
<encodingDesc>
```

encodingDesc > projectDesc

- On peut combiner les deux :

```
<encodingDesc>
    <projectDesc>
        <p>Description du projet</p>
    </projectDesc>
    <editorialDecl>
        <p>Description des normes d'encodage et de transcription</p>
    </editorialDecl>
<encodingDesc>
```

Les TEI subsets

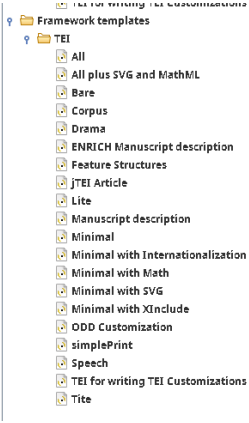

- Quand on ouvre un document XML avec Oxygen, les des spécifications de la TEI sont disponibles
- On va commencer à travailler avec TEI All.

Exercice : encoder les metadonnées du *Dormeur du val*

- Proposez un encodage minimal des metadonnées du poème de Rimbaud. Vous reprenez un poème édité ailleurs, et êtes responsable de son encodage. Proposez une licence de diffusion libre (Creative Commons par exemple) de votre édition.
- Commencez par ouvrir un nouveau document avec la spécification « TEI All »
- Vérifiez bien que votre encodage est correct avec « Valider » :

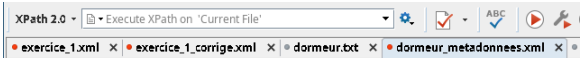

Figure – Le bouton de validation figure un icone de page avec une encoche (rouge)

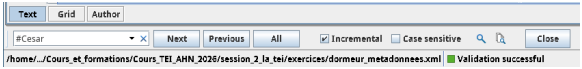

Figure – Le document est valide : un message doit s'afficher en bas du logiciel avec un carré vert

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux
  - Métadonnées
  - Structures textuelles
  - Représentation des sources primaires
  - Description de manuscrits
  - Entités nommées
  - Apparats critiques

Structure textuelle

- Les divisions sont marquées par `div` ou `div1, div2, div3`. Le choix entre les deux est obligatoire !
- Les paragraphes de la prose, par `p`
- Les sections moins marquées sémantiquement peuvent être indiquées par `ab` (anonymous block)
- On peut enchâsser les divisions, mais (logiquement) pas les paragraphes.

Structure textuelle : attributs

- Dans le cas du choix des éléments `div` no numérotés, il est important de préciser le niveau de structure à l'aide d'attributs
- On utilisera d'une part l'attribut `@type` pour la classification du niveau structurel
- On utilisera de l'autre l'attribut `@n` pour la numéro de la structure courante
- Il est parfois utile de créer des identifiants uniques pour chaque unité structurelle, afin de pouvoir la retrouver facilement ensuite. On utilise alors l'attribut xml `@xml:id`
- Attention, **@xml :id n'accepte que des valeurs uniques dans un même document**

Exercice

- Dans un nouveau document XML-TEI (Spécification « All »), encodez la structure minimale de l'incipit de la *Recherche*, comme si vous deviez éditer le texte intégral.

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux
  - Métadonnées
  - Structures textuelles
  - Représentation des sources primaires
  - Description de manuscrits
  - Entités nommées
  - Apparats critiques

Représentation des sources primaires

- Un chapitre est consacré aux méthodes d'encodage des sources primaires.
- Il permet de décrire les phénomènes visibles dans les pages ou feuillets d'un livre.
- Ce module est disponible ici :
  https ://www.tei-c.org/release/doc/tei-p5-doc/fr/html/PH.html

Représentation des sources primaires

Les principales caractéristiques sont

- Description de l'organisation du livre, du recueil ou de la page :
  - changement de ligne : `lb` pour **line beginning**
  - changement de page : `pb` pour **page beginning**
  - changement de colonne : `cb` pour **column beginning**
  - changement de cahier : `gb` pour **gathering beginning**
- Altération du texte « originel » :
  - ajouts : `add`
  - suppressions, biffages : `del`
  - substitutions : `subst` avec les éléments antérieurs combinés
- Interventions éditoriales :
  - expansions d'abréviations : `abbr` `expan`
  - corrections : `sic` et `corr`
  - Ces interventions apparaissent dans un élément `choice` (« alternative encodings for the same point in a text »)

Exercice

- En reprenant votre encodage de l'*incipit* de la *Recherche*, ainsi que le texte disponible sur wikisource, marquez les changements de page tels qu'ils apparaissent dans l'édition de 1946.

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux
  - Métadonnées
  - Structures textuelles
  - Représentation des sources primaires
  - Description de manuscrits
  - Entités nommées
  - Apparats critiques

Description de manuscrits

- Ce module peut être confondu avec le module précédent, mais il concerne la description physique du manuscrit et non pas la description de la page.
- On trouvera donc ses éléments essentiellement dans le `teiHeader`, et plus précisément dans le `sourceDesc`
- On en trouvera les spécificité dans https ://tei-c.org/release/doc/tei-p5-doc/en/html/MS.html

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux
  - Métadonnées
  - Structures textuelles
  - Représentation des sources primaires
  - Description de manuscrits
  - Entités nommées
  - Apparats critiques

Entités nommées

- Une entité nommée est une chaîne de caractères qui décrit un référent humain, géographique ou institutionnel (personne, lieu, entreprise, organisation, etc).
- La TEI propose un ensemble d'éléments permettant d'identifier les entités nommées dans le texte, et de les désambiguiser (dans le teiHeader).

Identifier les entités nommées

```
<seg type="exemple">
    e dize más
    <app type="lemmes">
        <lem wit="#E #R #D #F #Z">de</lem>
        <rdg wit="#Q"/>
    </app>
    <persName ref="#Cesar">Çesar</persName> que la cobdiçia e la mala manera
    ↪  de sobrepujar sobre los otros [...]
</seg>
```

Désambiguiser les entités nommées

- On a besoin d'indiquer le référent de chaque entité, ce que l'on peut faire en plusieurs points de l'édition
- La plus commune est dans le `teiHeader`
- Il s'agit de proposer une liste de personnes (`listPerson`), ou de lieux (`listPlace`)
- Ces deux éléments seront présents dans l'élément `sourceDesc`

Désambiguiser les entités nommées : exemple

```
<sourceDesc>
    <listPerson type="personnages">
        <person xml:id="AlexandrelG">
            <persName>Alexandre le Grand</persName>
        </person>
        <person xml:id="SCatherine">
            <persName>Sainte Catherine</persName>
        </person>
        <person xml:id="Cincinnatus">
            <persName>Cincinnatus</persName>
        </person>
        <person xml:id="Cesar">
            <persName>César</persName>
        </person>
    </listPerson>
</sourceDesc>
```

Désambiguiser les entités nommées : exemple

On peut aller assez loin dans la description biographique d'une personne

```
<person xml:id="Ovi01" sex="M" role="poet">
    <persName xml:lang="en">Ovid</persName>, <persName xml:lang="la">Publius
    ↪  Ovidius Naso</persName>
    <birth when="-0044-03-20"> 20 March 43 BC
        <placeName>
            <settlement type="city">Sulmona</settlement>
            <country key="IT">Italy</country>
        </placeName>
    </birth>
    <death notBefore="0017" notAfter="0018">17 or 18 AD
        <placeName>
            <settlement type="city">Tomis (Constanta)</settlement>
            <country key="RO">Romania</country>
        </placeName>
    </death>
</person>
```

1 Organisation de la TEI
- Éléments et attributs
- Des objets définis et illustrés
- Les chapitres thématiques de la TEI
- Chapitres fondamentaux
  - Métadonnées
  - Structures textuelles
  - Représentation des sources primaires
  - Description de manuscrits
  - Entités nommées
  - Apparats critiques

Apparats critiques

- Il existe également un module spécifique dédié aux apparats critiques : le module textcrit. Il permet d'encoder une édition critique selon plusieurs écoles philologiques (lachmannisme, néo-lachmannisme, bédiériste, *New Philology)*.
- Lien vers le chapitre des *Guidelines* :
  https ://tei-c.org/release/doc/tei-p5-doc/en/html/TC.html

1 Organisation de la TEI

2 Application : encoder des vers et du théâtre

2 Application : encoder des vers et du théâtre
- Le vers
  - Exercice 1
- Le théâtre

Les formes versifiées

- Le module de la TEI est : https ://tei-c.org/release/doc/tei-p5-doc/en/html/VE.html
- les éléments fondamentaux sont le vers (`l` pour *line*),
- le groupe de vers (`lg` pour *LineGroup*)

Les formes versifiées

- Vous pouvez représenter une unité textuelle (poème) par comme un `lg` ou plus classiquement une division.
- L'hémistiche ou le pied peuvent être indiqués à l'aide de l'élément `seg` qui devra être précisé par un attribut `type`

```
<lg type="chant" n="1">
    <lg>
        <l>Arma virumque cano, Troiae qui primus ab oris</l>
        <l>italiam, fato profugus, Laviniaque vnit</l>
        <l>litora, multum ille et terris iactatus et alto</l>
        <l>vi superum saevae memorem Iunonis ob iram;</l>
        <l>multa quoque et bello passus, dum conderet urbem,</l>
        <l>inferretque deos Latio, genus unde Latinum,</l>
        <l>Albanique patrs, atque altae moenia Romae.</l>
    </lg>
</lg>
```

Les formes versifiées

- Vous pouvez décrire la rime avec l'attribut `rhyme` :

```
<lg type="soneto">
    <lg rhyme="ABAB" type="cuarteto" n="1">
        <l>Tengo miedo a perder la maravilla</l>
        <l>de tus ojos de estatua y el acento</l>
        <l>que me pone de noche en la mejilla</l>
        <l>la solitaria rosa de tu aliento.</l>
    </lg>
    ...
</lg>
```

Les formes versifiées

- Vous pouvez décrire la structure métrique avec `met` :

```
<l met="+--|+--|++|++|+--|++">
Arma virumque cano Troiae qui primus ab oris
</l>
```

ou encore

```
<l>
 <seg type="foot" met="+--">Arma vi</seg>
 <seg met="+--">rumque ca</seg>
 <seg met="++">no Tro</seg>
 <seg met="++">iae qui </seg>
 <seg met="+--">primus ab</seg>
 <seg met="++"> oris</seg>
</l>
```

2 Application : encoder des vers et du théâtre
- Le vers
  - Exercice 1
- Le théâtre

Encoder un sonnet

- Encodez le sonnet
- Utilisez la spécification `TEI All` (nous y reviendrons dans la session 3)
- Commencez par renseigner les métadonnées minimales
- Encodez la structure du poème en considérant qu'il fait partie d'un recueil plus vaste
- Renseignez le type de strophe et de vers à l'aide d'attributs

2 Application : encoder des vers et du théâtre
- Le vers
- Le théâtre
  - Exercice 2

Le théâtre

- Le module de la TEI est : https ://tei-c.org/release/doc/tei-p5-doc/en/html/DR.html
- les éléments fondamentaux sont la division structurelle (similaire à *supra*), les interventions des personnages (`sp`)
- L'indication de parole est réalisée à l'aide de `speaker`.

```
<div type="scene" n="1">
    <head>Scène Première</head>
    <stage>Philinte, Alceste</stage>
    <sp>
        <speaker who="#philinte">Philinte</speaker>
        <l n="1">Qu'est-ce donc ? qu'avez-vous ?</l>
    </sp>
    <sp who="#alceste">
        <speaker>Alceste</speaker>
        <stage>assis</stage>
        <l n="1">Laissez-moi, je vous prie.</l>
    </sp>
</div>
```

Le théâtre

- Les didascalies sont encodées avec `stage`. Les mouvements des personnages, avec `move`
- La liste des personnages se décrit à l'aide de `castList` et de `castItem`, le lieu de l'action avec `set`.

```
<body>
     <head>Le misanthrophe</head>
     <castList>
        <castItem xml:id="philinte">Philinte</castItem>
        <castItem xml:id="alceste">Alceste</castItem>
     </castList>
    <div xml:id="I" type="act" n="1">
        <head>Acte Premier</head>
        ...
    </div>
</body>
```

2 Application : encoder des vers et du théâtre
- Le vers
- Le théâtre
  - Exercice 2

Encoder un fragment d'œuvre dramatique

- Encodez la scène finale de l'*Avare* (`session_2_la_tei/exercices/avare_a5_sc6.txt`)
- Utilisez la spécification `TEI Drama`
- Commencez par renseigner les métadonnées minimales
- Encodez la structure du texte en considérant qu'il fait partie d'une œuvre complète