Session 3: Les schémas

Atelier Humanités Numériques

Lyon

Matthias Gille Levenson

Université Versailles Saint Quentin (UVSQ) & École Normale Supérieure de Lyon, France

matthias [dot] gille [-] levenson [at] ens-lyon [dot] fr

24 mars 2026

1 Introduction

2 Les schémas

3 Conclusions

4 Une dernière chose: ODDbyexample

5 Exercise

1 Introduction

2 Les schémas

3 Conclusions

4 Une dernière chose: ODDbyexample

5 Exercise

2 Les schémas
- Avantages de l'utilisation des schémas
- Les schémas et la TEI I
- Les schémas and la TEI II: l'ODD
- ROMA

À quoi sert un schéma ?

- Un schéma vérifie si les données sont correctement formatées.
- Un schéma définit des règles concernant ce qui est autorisé et ce qui ne l'est pas dans une structure de données XML
- Appliqué à un codage de texte, un schéma est un modèle du "texte", c'est-à-dire une **représentation formelle** du texte.
- D'un point de vue pratique, cela permet d'harmoniser votre encodage et constitue une **étape importante vers l'interopérabilité**

Intégration du schéma dans vos sessions d'encodage

Certains éditeurs XML utilisent le schéma comme outil pour faciliter le codage :

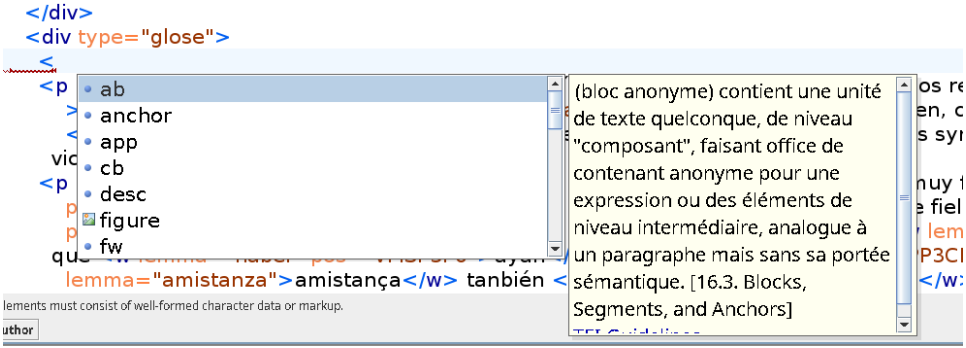

Figure: L'éditeur XML Oxygen vous permet de choisir parmi les éléments autorisés

Les schémas

- Un schéma est un document qui sert à contrôler la qualité d'un encodage.
- La TEI fournit des **règles** (les *Guidelines*, lisibles par l'homme) et leur **formalisation** (*schémas*, lisibles par machine) afin de vérifier la validité d'un document donné
- D'un point de vue abstrait, le schéma représente la formalisation de *votre* modélisation d'un texte ou d'un genre donné.

Les schémas

```
TEI  text  body  div  div  div  lb
1803   <body>
1804     <div type="livre" n="1">
1805       <div type="partie" n="2">
1806         <div type="chapitre" n="1"><pb n="" facs="../input_files/16369405.jpg"/><fw
1807           type="titre_courant"/><lb break="?" rend="rubric"
1808           xml:id="elem_eSc_line_99cc2a93"/>Capitulum . i. lquno diuiduntur potencie<lb
1809           break="yes" rend="rubric"
1810           xml:id="elem_eSc_line_7f955f55"/>anime et in quibus potenciis habet esse uirtutes. <lb
1811           break="yes"
1812           xml:id="elem_eSc_line_6ea8e267"/>ostquam auxiliante deo compleui<lb break="no"
1813           xml:id="elem_eSc_line_df9d9bc9"/>mus primampartem huius primi libri inquo<lb
1814           break="yes"
1815           xml:id="elem_eSc_line_b36db744"/>agitur de regimine sui ostendentes<lb break="no"
1816           xml:id="elem_eSc_line_2c352677"/>i quo reges et p̃ncipes suam felici □□ poner<lb
1817           break="no"
1818           xml:id="elem_eSc_line_54b88267"/>e d□ quia non decet eos suum finem pone in din<lb
1819           break="no"
1820           xml:id="elem_eSc_line_a6468504"/>ciis. nec in ciuili potentia. nec in aliquibus
1821         talibus sed omni<lb break="no"
1822           xml:id="elem_eSc_line_5efa6adc"/>bus hiis ut supra plenius perba debet uti tanquam<lb
1823           break="yes"
1824           xml:id="elem_eSc_line_33a63380"/>organis ad felicitatem sed poneredz in a<lb
1825           break="no"
1826           xml:id="elem_eSc_line_c991f46c"/>ctu pruden □ prout talis actus est inpatu□□<lb
1827           break="yes"
1828           xml:id="elem_eSc_line_388d53ce"/>a cari □□ Nam tunc reges habet felicita<lb
1829           break="no"
1830           xml:id="elem_eSc_line_4b955e3e"/>tem suo statui debitas et condignam quando<lb
1831           break="yes"
1832           xml:id="elem_eSc_line_c422ed80"/>instigante dei dilectione secundum prudenciam<lb
1833           break="yes"
text not allowed here; expected the element end-tag or element "ab", "addSpan", "alt", "altGrp", "anchor", "annotationBlock", "app", "argument", "bibl", "biblFull", "biblStruct", "byline", "camera", "caption", "castList",
```

Figure: Ce fragment est *bien formé*, mais il n'est pas *valide* selon le schéma XML-TEI. Ces lignes devraient être encadrées par un paragraphe `p` ou un bloc anonyme `ab`.

Formats de schémas

Il existe plusieurs formats de schéma. Les plus importants sont les suivants :

- Définition de type de document (DTD)
- Schéma XML (format XSD)
- Schémas Relax NG (RNG) et leur version compacte (RNC)

2 Les schémas
- Avantages de l'utilisation des schémas
- Les schémas et la TEI I
- Les schémas and la TEI II: l'ODD
- ROMA

Les TEI subsets

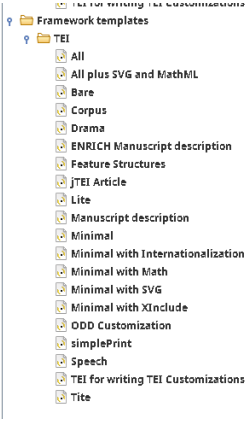

- Il existe plusieurs schémas TEI.
- En tant que norme scientifique, le TEI doit être adapté aux besoins de l'utilisateur.ice

Pourquoi devriez-vous créer votre propre personnalisation TEI ?

- Considérez la TEI comme un outil permettant de modéliser votre objet textuel
- Vous n'aurez probablement pas besoin de tous les outils conceptuels fournis par le Consortium TEI.
- Si vous êtes médiéviste, vous souhaiterez peut-être écarter les éléments appartenant à la section "Transcriptions du discours" de la TEI (hélas !)
- Votre schéma sera la formalisation de votre façon de voir le texte, et vous devez le rendre aussi précis que possible.

Deux méthodes principales

- La méthode par inclusion : partez de zéro, ajoutez les éléments dont vous avez besoin
- La méthode par exclusion : partez d'un schéma prédéfini, supprimez les éléments dont vous n'avez pas besoin

Deux méthodes principales

- La méthode par inclusion : partez de zéro, ajoutez les éléments dont vous avez besoin
- La méthode par exclusion : partez d'un schéma prédéfini, supprimez les éléments dont vous n'avez pas besoin
- Je vous recommanderais d'adopter la première approche...

Deux méthodes principales

- La méthode par inclusion : partez de zéro, ajoutez les éléments dont vous avez besoin
- La méthode par exclusion : partez d'un schéma prédéfini, supprimez les éléments dont vous n'avez pas besoin
- Je vous recommanderais d'adopter la première approche...
- ou du moins de partir d'une spécification prédéfinie qui répond à certains de vos besoins (nous verrons cela plus tard).

Deux méthodes principales

- La méthode par inclusion : partez de zéro, ajoutez les éléments dont vous avez besoin
- La méthode par exclusion : partez d'un schéma prédéfini, supprimez les éléments dont vous n'avez pas besoin
- Je vous recommanderais d'adopter la première approche...
- ou du moins de partir d'une spécification prédéfinie qui répond à certains de vos besoins (nous verrons cela plus tard).
- Il est essentiel de maîtriser les lignes directrices pour savoir ce qui est possible pour votre projet.

Ne réinventez pas la roue !

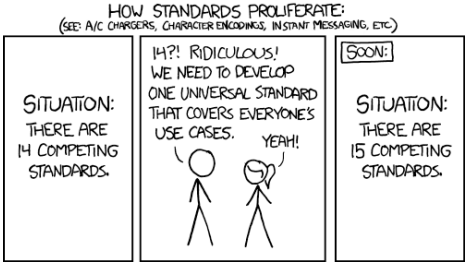

Figure: `https://xkcd.com/927/`

- Vous devez définir et adapter les règles TEI à votre propre projet
- Cependant, les problèmes de modélisation auxquels vous serez confronté ne sont probablement *pas* nouveaux
- Ne réinventez pas la roue !
- Recherchez ce qui a déjà été fait pour des problèmes similaires et essayez les solutions proposées !
- Et (pour commencer), évitez d'inventer ou de créer de nouveaux éléments.

2 Les schémas
- Avantages de l'utilisation des schémas
- Les schémas et la TEI I
- Les schémas and la TEI II: l'ODD
- ROMA

Is that all, folks ?

- Créer un schéma spécifique est un bon début.

Is that all, folks ?

- Créer un schéma spécifique est un bon début.
- Que manque-t-il alors ?

Is that all, folks ?

- Créer un schéma spécifique est un bon début.
- Que manque-t-il alors ? *De la documentation.*

Is that all, folks ?

- Créer un schéma spécifique est un bon début.
- Que manque-t-il alors ? *De la documentation.*
- Vous souhaitez maintenant expliquer vos règles à votre supérieur, à vos collègues et à vos enfants. Vous devez rédiger cela *en langage naturel*.

Is that all, folks ?

- Créer un schéma spécifique est un bon début.
- Que manque-t-il alors ? *De la documentation.*
- Vous souhaitez maintenant expliquer vos règles à votre supérieur, à vos collègues et à vos enfants. Vous devez rédiger cela *en langage naturel*.
- Quoi de mieux qu'un document TEI pour décrire un autre document TEI ?

Here comes the ODD

- ODD signifie "One Document Does it All"
- Un ODD est un document TEI qui sert à créer à la fois la documentation et le schéma dans un seul et même document.
- Lecture recommandée : Lou Burnard. "What Is TEI Conformance, and Why Should You Care?" In: *Journal of the Text Encoding Initiative* 12 (2019). ISSN: 2162-5603

Un Document pour les Contrôler Tous

Un ODD contient :

- les éléments lisibles par machine utilisés pour *valider* une édition
- les éléments lisibles par l'homme utilisés pour *documenter* celle-ci

Text Body

- 1 The TEI Infrastructure
- 2 The TEI Header
- 3 Elements Available in All TEI Documents
- 4 Default Text Structure
- 5 Characters, Glyphs, and Writing Modes
- 6 Verse
- 7 Performance Texts
- 8 Transcriptions of Speech
- 9 Computer-mediated Communication
- 10 Dictionaries
- 11 Manuscript Description
- 12 Representation of Primary Sources
- 13 Critical Apparatus
- 14 Names, Dates, People, and Places
- 15 Tables, Formulæ, Graphics, and Notated Music
- 16 Language Corpora
- 17 Linking, Segmentation, and Alignment
- 18 Simple Analytic Mechanisms
- 19 Feature Structures
- 20 Graphs, Networks, and Trees
- 21 Non-hierarchical Structures
- 22 Certainty, Precision, and Responsibility
- 23 Documentation Elements
- 24 Using the TEI

- Le TEI est organisé en modules *thématiques* qui correspondent aux chapitres indiqués plus haut
- Le module est la formalisation informatique du chapitre.

TEI as modules

- 22 modules
- Chaque module est associé à une liste d'éléments. Si vous désactivez un module, ces éléments ne seront plus accessibles.
- 4 modules principaux : `tei`, `core`, `header` et `textstructure`, pratiquement obligatoires

Un ODD n'est PAS un schéma

- Il s'agit d'un **document TEI** utilisé pour générer des schémas.
- Il doit être **converti** en schéma (et en documentation, le cas échéant).
- Le schéma obtenu (généralement au format RNG) est le document que vous utiliserez pour valider vos documents XML.
- N'essayez pas de valider vos fichiers par rapport aux ODD !

2 Les schémas
- Avantages de l'utilisation des schémas
- Les schémas et la TEI I
- Les schémas and la TEI II: l'ODD
- ROMA

Création de fichiers ODD et de schémas avec ROMA

- ROMA, géré par Raffaele Viglianti (responsable), Peter Stadler et Bryan Wang.
- ROMA est une interface simple permettant de concevoir des ODD et de créer des schémas
- URL : `https://roma.tei-c.org/`

A quick look at our ODD

With ROMA, you can easily design your own ODD:

- Inclure ou exclure des modules spécifiques
- Supprimer complètement des éléments (ils ne seront plus autorisés)
- Imposer des contraintes sur les types d'attributs ou les valeurs d'attributs
- Rendre certains attributs obligatoires
- etc.

Création de fichiers ODD et de schémas avec ROMA

- Je m'intéresse au codage d'un manuscrit médiéval. Comment puis-je créer le fichier ODD le plus adapté avec ROMA ?
- Je souhaite m'assurer que l'utilisateur utilise l'attribut `@n` pour chaque élément de début de page (`pb`). Comment puis-je procéder ?
- Je souhaite supprimer les éléments `div1`, `div2`, ..., `div7`, afin que les divisions soient balisées uniquement avec des éléments `div` typés et identifiés.

Création de fichiers ODD et de schémas avec ROMA

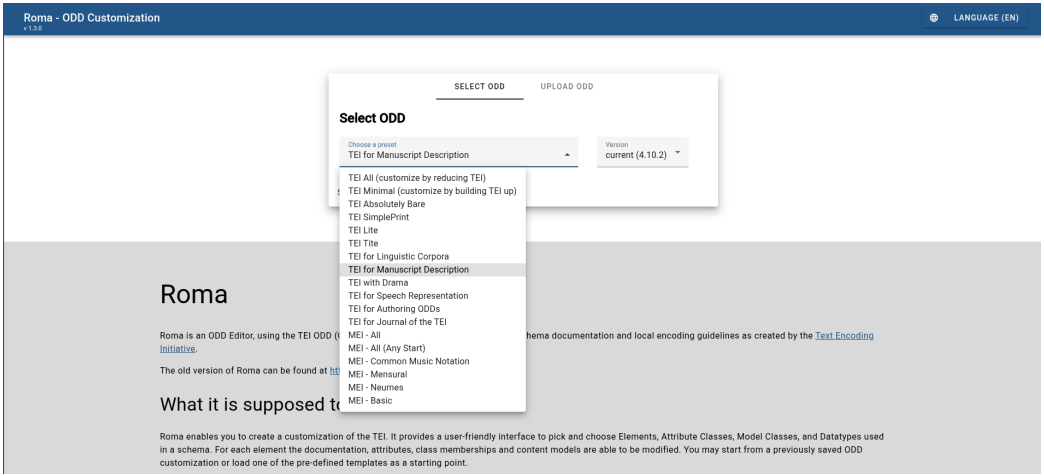

Figure: La page principale de ROMA: les “presets”

Création de fichiers ODD et de schémas avec ROMA

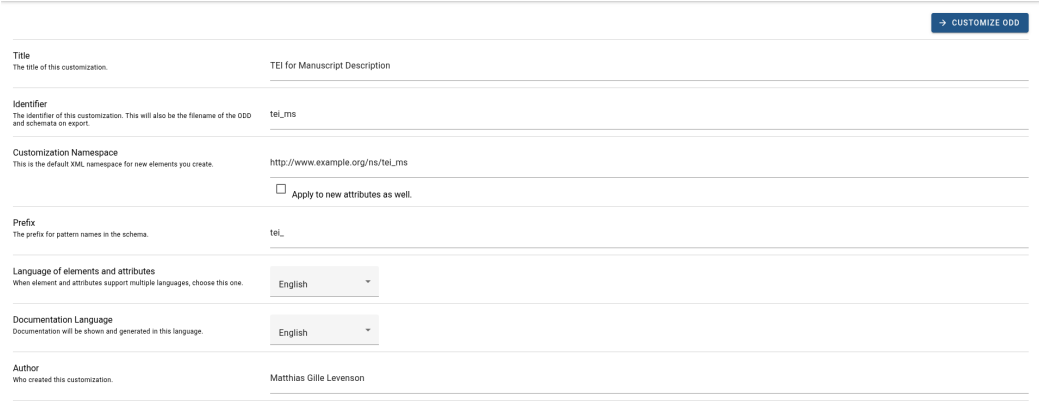

Figure: Configurer l'ODD

Création de fichiers ODD et de schémas avec ROMA

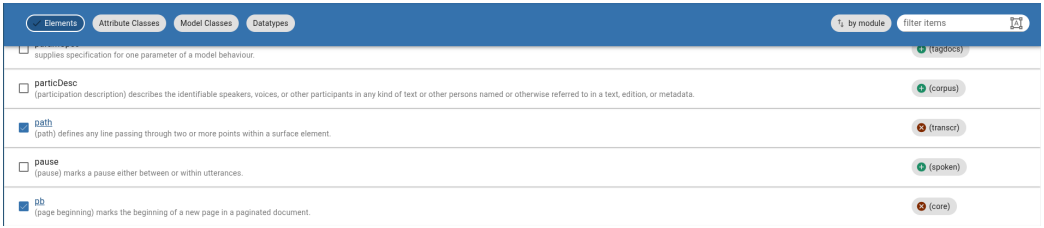

Figure: Recherchez l'élément que vous souhaitez modifier (ici, pb)

Création de fichiers ODD et de schémas avec ROMA

Figure: Choisissez l'élément que vous souhaitez adapter (documentation ou attribut)

Création de fichiers ODD et de schémas avec ROMA

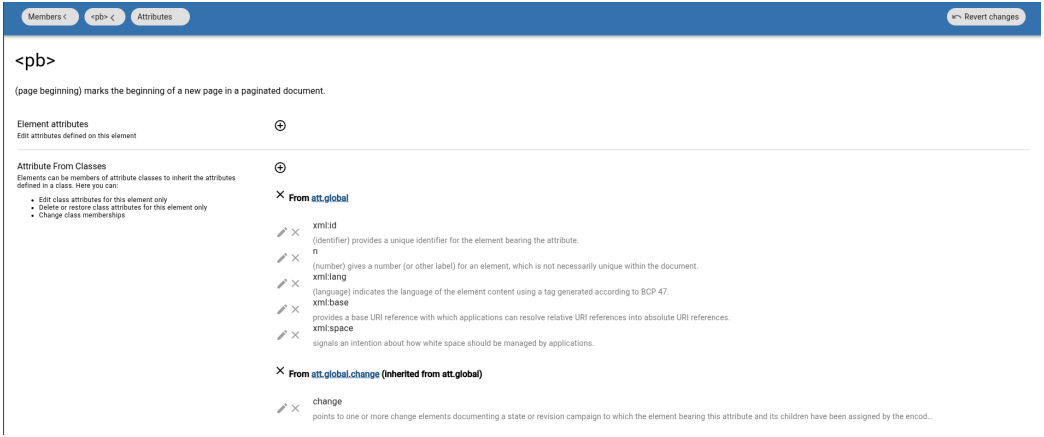

Figure: Recherchez l'attribut que vous souhaitez modifier

Création de fichiers ODD et de schémas avec ROMA

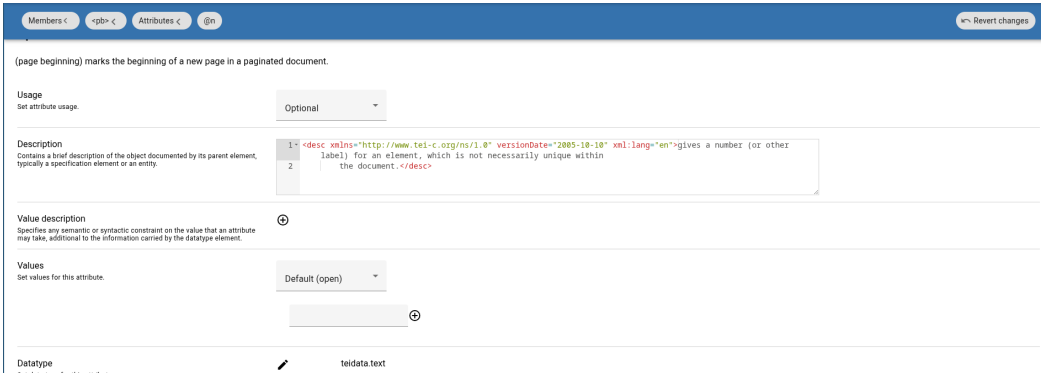

Figure: Changez la façon de l'utiliser ! C'est (presque) automagique !

L'ODD produit

```
      </encodingDesc>
    </teiHeader>
    <text>
      <body>
        <p>TEI for manuscript description</p>
        <schemaSpec ident="tei_ms" start="TEI teiCorpus" prefix="tei_" targetLang="en"
          docLang="en">
          <moduleRef key="header"/>
          <moduleRef key="linking"/>
          <moduleRef key="core"/>
          <moduleRef key="tei"/>
          <moduleRef key="textstructure" except="div1 div2 div3 div4 div5 div6 div7"/>
          <moduleRef key="namesdates"/>
          <moduleRef key="transcr"/>
          <moduleRef key="figures"/>
          <moduleRef key="msdescription"/>
          <elementSpec ident="pb" mode="change">
            <attList>
              <attDef ident="n" mode="change" usage="req"/>
            </attList>
          </elementSpec>
        </schemaSpec>
      </body>
    </text>
  </TEI>
```

Je trouve cette spécification trop générale. Je supprimerais certains modules. Souhaitez-vous décrire des chiffres ? Vous intéressez-vous aux entités nommées ?

Création d'ODD et de schémas avec ROMA : exportation de l'ODD

- Plusieurs formats de sortie.
- Le plus important est l'ODD pour les applications scientifiques.
- Vous aurez besoin de RNC/RNG à des fins de validation.
- Vous ne pourrez pas récupérer votre ODD à partir d'un RNG ou de tout autre fichier de schéma.
- Oxygen peut également générer le schéma à partir des ODD.

Faire référence au schéma dans votre fichier TEI

```
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE TEI SYSTEM "/home/mgl/Bureau/These/Edition/hyperregimiento-de-los-principes/Dedans/XML/schemas/Esc_Q.dtd">
<?xml-model href="../../schemas/out/ODD_edition.rng" type="application/xml" schematypens="http://relaxng.org/ns/structure/1.0"?>
<TEI xmlns="http://www.tei-c.org/ns/1.0" xml:id="Esc_Q" type="transcription">
 <teiHeader>
```

Figure: Avant le nœud racine, la référence à mon schéma dérivé de l'ODD (en violet, troisième ligne).

Un aperçu de notre ODD

Résumons. Vous pouvez:

- Supprimer complètement certains éléments (ils ne seront plus autorisés)
- Supprimer partiellement certains éléments (ils ne seront autorisés que dans des contextes spécifiques)
- Restreindre les types d'attributs ou leurs valeurs ; rendre certains attributs obligatoires

L'autre facette des ODD : la documentation en langage naturel

- Roma n'est que la première étape pour créer la version lisible par machine de votre ODD
- Comme indiqué précédemment, vous devrez créer et rédiger la documentation *en langage naturel*, en utilisant le TEI. Exemple : ici.
- Vous pouvez utiliser n'importe quel éditeur XML pour ce faire.

```
<p>Enfin, il est important pour une bonne intelligence du texte, d'aller marquer des divisions structurelles et
  logiques qui se trouvent au sein des paragraphes. C'est pourquoi je propose d'utiliser des balises vides
    <gi>milestone</gi> qui vont marquer, dans un même paragraphe, des énumérations par exemple (méthode moins
  lourde qu'en utilisant <gi>list</gi>): <egXML xmlns="http://www.tei-c.org/ns/Examples">E <w lemma="este"
      pos="PD0MS000">este</w> es el primero capitulo <w lemma="de+este">desta</w>
    <w pos="NCFS000">parte</w> postrimera que <w lemma="estar" pos="VMIP3S0">esta</w> en tres conclusiones.
      <milestone type="structuration_discours" unit="item_rang_1" n="1"/>La primera es que cosa es <w
      lemma="caballería">caualleria</w>. <milestone type="structuration_discours" unit="item_rang_1" n="2"
    />La <w lemma="2" pos="AO0FS0">segunda</w> por que fue fecha e establecida.</egXML></p>
```

Figure: Documentation de l'utilisation de `milestone` dans l'édition du *Regimiento de los prínçipes*.

1 Introduction

2 Les schémas

3 Conclusions

4 Une dernière chose: ODDbyexample

5 Exercise

Conclusions

- Les Même les schémas les plus simples sont indispensables à tout projet de publication scientifique basé sur TEI.
- Les éditions basées sur TEI qui ne sont pas accompagnées des sources XML sont pratiquement inutiles et ne feront pas long feu
- Veuillez donner accès à vos données (et à leur documentation) !

1 Introduction

2 Les schémas

3 Conclusions

4 Une dernière chose: ODDbyexample

5 Exercise

ODDbyexample

- ODDByExample est un outil permettant de générer une spécification ODD à partir d'un document XML-TEI existant
- Il créera une spécification ODD correspondant à ce document
- Un outil très utile...
- ... qui peut toutefois poser problème si l'exemple XML-TEI présente des incohérences : celles-ci seront intégrées à votre spécification
- Veillez à utiliser cet outil avec des fragments de votre document courts et soigneusement vérifiés.
- Lien : https://github.com/TEIC/Stylesheets/blob/dev/tools/oddbyexample.xsl

1 Introduction

2 Les schémas

3 Conclusions

4 Une dernière chose: ODDbyexample

5 Exercise

Exercises

- Reprenez l'encodage de votre poème, et créez un ODD qui reprend cette modélisation.

References

Burnard, Lou. “What Is TEI Conformance, and Why Should You Care?” In: *Journal of the Text Encoding Initiative* 12 (2019). ISSN: 2162-5603.